

# 9月24日计划

---

8月份参加了中信集团的横向，中信那边要求8月底完成，所以主要在做那边的项目。另外在校外无法连接校内服务器，且act实验室账号被关停，所以实验拖到了9月。

目标：在9月24日投稿截止前，围绕 GoT 节点跳过完成一套实验闭环：完整数据集熵分布、随机跳过 baseline、LLM judge 节点评估、以及融合结构信息的初步结论。

## 运行速度约束

---

目前运行 doc\_merge 的速度是：

- 5 小时完成 15 条数据
- 平均 3 条/小时
- 跑完 100 条约需要 33.3 小时，保守按 34 小时计算

目前考虑并行运行。从9月6日开始运行，预计9月8日可以获得doc\_merge完整的图，以及按照高熵和低熵跳过的图。

## 总体优先级

---

必须完成：

1. doc\_merge、sorting\_128、set\_intersection\_128的100 条 full/low/high 结果。
2. 熵分布与结果相关性分析。
3. 引入LLM judge，对实验结果至少 20 条做节点有效性打分，最好覆盖 100 条已有 full\_graph。

尽量完成：

1. judge 分数与 entropy、operation type、节点位置、score 的相关性分析。
2. 基于 judge 的候选 skip 节点排序。

可选完成：

1. 训练一个轻量 judge/classifier。
2. 扩展测试 keyword\_counting 等新的数据。

## 9月6日-9月7日：确定实验运行链路

---

目标：确保批量实验、并行实验、judge 分析都能稳定运行。

任务：

- 检查 doc\_merge 当前 15 条输出是否正常。
- 确认 full\_graph.json、candidate\_ranking.csv/json、summary.json 是否完整。
- 跑一个小规模 judge：

验收标准：

- judge 能输出 judge\_scores.csv
- skip\_risk/usefulness/redundancy 字段能正常解析
- 不重新跑 full GoT 时能正确读取已有 full\_graph.json

## 9月6日-9月9日：优先跑 doc\_merge 100 条

---

目标：先拿到最重要的完整数据集结果。

这几天的工作方式：

- 实验在后台跑。
- 每隔 2-3 小时检查一次 `run.log` 和失败样例。
- 先分析已经完成的前 15 条。

验收标准：

- 失败样例有 `error.log`，能定位原因。
- 每条至少有 `full_graph.json` 和 low/high 的 `summary.json`。

## 9月10日-9月13日：跑随机 baseline 和熵分布分析

---

目标：回答“熵和结果相关性是否足够高”“随机跳过节点是什么样子”。

对 doc\_merge 已有结果做随机 baseline：

同时跑 `sorting_128` 和 `set_intersection_128` 前 20 条：

需要整理的表：

- 每个任务的 entropy mean/std/min/max/IQR。
- 低熵 20% 均值、高熵 20% 均值、高低熵差距。
- low skip、high skip、random skip 的结果质量和 token/API/cost 节省。
- 随机跳过节点的 operation 类型分布。

预期结论方向：

- token 熵衡量的是生成不确定性，不等于节点重要性。
- 如果 random skip 反而更好，说明固定跳高熵/低熵会集中破坏某类节点。
- aggregate 往往结构位置更关键，即使熵不一定最高，也不能简单跳过。

## 9月14日-9月16日：LLM judge 抽样分析

---

目标：先验证 judge 是否能提供比 entropy 更直接的节点有用性信号。

先对 doc\_merge 前 20 条做 judge，如果费用和速度可接受，再跑 100 条：

需要分析：

- `skip_risk` 最低的节点是什么 operation。
- `redundancy` 最高的节点是否确实重复。
- `usefulness` 和 entropy 是否相关。
- judge 认为低风险的节点，是否和 random 成功跳过的节点重合。

验收标准：

- 至少有 20 条 doc\_merge 的 judge 结果。
- 每个样例有 `judge_scores.csv` 和 `judge_summary.json`。
- 能列出 5-10 个“适合跳过”和“不适合跳过”的典型节点。

## 9月17日-9月18日：补充结构特征分析

---

目标：回答“仅凭 token 熵是否还不够，是否需要结构位置、operation 类型、候选得分、后续选择信息”。

需要统计每个 candidate thought：

- operation：generate / aggregate / improve
- operation\_index
- 图深度或相对位置：前期/中期/后期
- predecessor 数量
- successor 数量
- entropy
- score
- 是否被 KeepBestN 选中
- judge skip\_risk
- judge usefulness
- judge redundancy

建议形成一个规则判断：

优先跳过：

- judge skip\_risk 低
- judge final\_answer\_contribution 低
- judge redundancy 高
- 没有被后续 KeepBestN 选中
- 同一 operation 下有多个备选 thought，且至少保留一个

谨慎跳过：

- aggregate
- 最终路径上的节点
- 早期拆分节点
- 被后续 KeepBestN 选中的节点
- 承载任务结构字段的节点，例如 keyword\_counting 的 aggr1/aggr2

这部分不一定必须马上改成新 skip 策略，但汇报时要有清晰证据说明：为什么需要这些特征。

## 9月17日-9月18日：根据情况选做 judge-skip 小实验

---

目标：如果时间允许，做一个小规模对比，证明 judge/hybrid 有潜力。

最小实验范围：

- doc\_merge 前 10 或 20 条。
- skip ratio 固定 0.2。
- 对比：

- low entropy
- high entropy
- random
- low judge skip\_risk
- hybrid: 低 skip\_risk + 高 redundancy + 非关键结构位置

如果来不及实现自动 replay，可以先做离线分析：

- judge 推荐跳过哪些节点。
- 这些节点和 low/high/random 已跳过节点的重合度。
- judge 推荐是否更少命中关键 aggregate 或最终路径节点。

## 9月18日-9月23日：整理结果和图表，撰写相关论文

目标：把实验材料变成汇报可用的表和图。

必须准备：

1. doc\_merge 100 条整体结果表。
2. 熵分布与区分度表。
3. low/high/random skip 对比表。
4. 随机跳过节点 operation 分布。
5. judge 分数分布。
6. entropy 与 judge skip\_risk/usefulness 的相关性。
7. 典型案例：
  - 低熵但不能跳
  - 高熵但关键
  - 随机跳过成功
  - 随机跳过失败
  - judge 判定冗余节点

建议主结论：

单一步骤 token 熵只能刻画模型生成不确定性，不能直接等价于 GoT 节点重要性。节点是否能跳过，还取决于 operation 类型、结构位置、候选得分、是否进入最终路径，以及它对最终答案的语义贡献。因此第一阶段应从“熵排序”扩展为“熵 + 结构 + judge”的可观测节点重要性分析。

## 风险和应对

| 风险                 | 影响         | 应对                            |
|--------------------|------------|-------------------------------|
| doc_merge 100 条跑不完 | 主结果不足      | 至少保证 50 条完整，100 条作为持续补充       |
| DeepSeek 限流        | 并行失败       | parallel-workers 从 5 降到 3 或 2 |
| judge 成本太高         | 无法全量 judge | 先 judge 20 条，再抽样扩展            |

| 风险                 | 影响           | 应对                                  |
|--------------------|--------------|-------------------------------------|
| entropy 和结果相关性弱    | 原假设受挑战       | 转为强调“熵不是节点重要性，需要结构和 judge”          |
| random baseline 更好 | low/high 不占优 | 用它证明单一排序策略存在偏差                      |
| doc_merge 无标准答案    | 正确性难评估       | 使用 LLM score、coverage、相似度、失败原因多指标评价 |