



基本设置

作业名称 *

DeepSeek-R1-Distill-Qwen-32B

名称可重复，最多包含 40 个字符

Master

副本数 *

1

CPU (核数) *16

内存 (GiB) *32

GPU (卡数) *4

GPU 型号 *

NVIDIA V100 32GB

启用 RDMA ?

InfiniBand (V100 128卡互联)

请保证同一个作业内的不同角色，均使用同一个 RDMA 网络拓扑

空闲资源查询

容器镜像 *

vLLM 0.8.3 (CUDA 12.4) with RDMA

启动命令

--gpu-memory-utilization 0.90 \
--max-num-seqs 128 \
--trust-remote-code \
--disable-custom-all-reduce \
python3 main.py

如果设置，将覆盖镜像的启动命令，可通过；拆分多行命令

工作目录

/models

用户文件夹位于 /home/pengxy26, 重启后数据不会丢失

⊕ 添加端口

 **Worker**

副本数 *

1

CPU (核数) *

16

内存 (GiB) *

32

GPU (卡数) *

4

GPU 型号 *

NVIDIA V100 32GB

启用 RDMA ?

InfiniBand (V100 128卡互联)

请保证同一个作业内的不同角色，均使用同一个 RDMA 网络拓扑

空闲资源查询

容器镜像 *

vLLM 0.8.3 (CUDA 12.4) with RDMA

启动命令

```
sleep 5; # wait 5s for ip loading
ray start --address="$MASTER_ADDR:6667";
sleep inf;
```

如果设置，将覆盖镜像的启动命令，可通过 ; 拆分多行命令

工作目录

/models

用户文件夹位于 /home/pengxy26，重启后数据不会丢失

添加端口



预设模板

DeepSeek R1 分布式推理

作者: 李亦龙

使用 2 台 4 卡 Tesla V100 SXM2 32GB 节点，启用 RDMA，推理 DeepSeek-R1-Distill-Qwen-32B 模型

Crater 平台 vLLM 多机部署 DeepSeek 实践

前言

随着大模型参数量的不断增大，单机的显存以无法完成模型的部署，在此我们将考虑如何通过多机的方式部署大参数模型。

vLLM 多机依赖于 Ray 分布式框架，但目前 Crater 平台还没有直接支持 KubeRay，因此我们可以借助 Pytorch 分布式训练作业的模板，Ray Head 对应于 Master，Ray Worker 对应于 Worker，从而完成分布式不同角色的设置。

实验过程

1. 申请实验环境

- 选取 vLLM 容器镜像
- 挂载模型目录

2. 构建 ray cluster

启动head节点：

```
ray start --head --port=6667 --disable-usage-stats
```

让 Worker 节点加入 Ray 集群：

```
# vllm-ray-worker  
ray start --address="$MASTER_ADDR:6667"
```

MASTER_ADDR 是在作业启动时注入到 Worker 节点中的变量，指向了 Master 节点的 IP。

- 检查构建情况

前面一共申请了2个4卡，通过ray status命令显示当前可用卡数为8卡GPU，构建成功

```
$ ray status  
===== Autoscaler status: 2025-04-14 08:49:59.361470 =====  
Node status  
-----  
Active:  
  1 node_d278865e305d2892d6659dfc59169b5f596956cf8413dcdb11491c85  
  1 node_3076595f2917222d64665013de4ef228917f3edfab50faa106e571b3  
Pending:  
  (no pending nodes)  
Recent failures:  
  (no failures)  
  
Resources  
-----  
Usage:  
  0.0/32.0 CPU  
  8.0/8.0 GPU (8.0 used of 8.0 reserved in placement groups)  
  0B/41.25GiB memory
```

0B/19.03GiB object_store_memory

Demands:

(no resource demands)

启动多机服务

由于单卡无法放下模型，这里采用张量并行（tp=8）的方式进行部署

```
python3 -m vllm.entrypoints.openai.api_server \
  --model=/models/DeepSeek-R1-Distill-Qwen-32B \
  --max-model-len 32768 \
  --tensor-parallel-size 8 \
  --gpu-memory-utilization 0.90 \
  --max-num-seqs 128 \
  --trust-remote-code \
  --disable-custom-all-reduce \
  --port 6666 \
  --dtype=half
```

请求测试

在 Master 节点的终端运行如下命令：

```
curl http://localhost:6666/v1/chat/completions \
  -H "Content-Type: application/json" \
  -d '{
    "model": "/models/DeepSeek-R1-Distill-Qwen-32B",
    "messages": [
      {
        "role": "user",
        "content": "测试一下是否正常输出"
      }
    ],
    "max_tokens": 150,
    "temperature": 0.7
  }'
```

你也可以启动 Web UI 界面和大模型交互，请参考 [Open WebUI 客户端](#)。

常见问题

- 问题1: ValueError: Bfloat16 is only supported on GPUs with compute capability of at least 8.0. Your Tesla V100-SXM2-32GB GPU has compute capability 7.0. You can use float16 instead by explicitly setting the dtype flag in CLI, for example: --dtype=half.
- 回答: 添加 vLLM 启动参数 --dtype=half，该问题主要原因是很多加速算子在v100上跑不起来的无奈之举，现在很多高性能算子都是有一定的硬件限制

- 问题2：如何预估需要申请多少算力？
- 回答：显存用量（最少） $\geq$ 模型参数量 * 部署位宽（bit） / 8，例如实例中使用32b的模型采用16bit进行部署，则最少需要64GB显存，crater中一张v100的显存为32GB，实际上3-4张v100就有可能跑起来，不用这块为了测试多机使用了8张卡
- 问题3：可以用sglang吗？
- sglang框架不支持使用7.0的显卡进行部署，vllm有些功能也不太支持在v100上用（具体有哪些可以自行去翻一翻vllm的文档和issue区）

参考资料

- <https://docs.vllm.ai/en/latest/>
- <https://zhuanlan.zhihu.com/p/29950052712>

① 作业说明

运行规则

2. 如果申请了 GPU 资源，当过去 2 个小时 GPU 利用率为 0，我们将尝试发送告警信息给用户，建议用户检查作业是否正常运行。若此后半小时 GPU 利用率仍为 0，**系统将释放作业占用的资源。**
3. 当作业运行超过 4 天，我们将尝试发送告警信息给用户，提醒用户作业运行时间过长；若此后一天内用户未联系管理员说明情况并锁定作业，**系统将释放作业占用的资源。**

环境变量

Pytorch 分布式作业相比普通的单机作业，在每个容器中都会设置环境变量：

1. WORLD_SIZE

- **作用：**表示参与分布式训练的进程总数（所有节点上的总进程数）。
- **示例：**WORLD_SIZE=2 表示总共有 2 个进程参与训练。

2. MASTER_ADDR

- **作用：**指定主节点（rank 0 的节点）的地址（通常是主机名或 IP 地址）。
- **示例：**MASTER_ADDR=py-liyilong-670a0-master-0.py-liyilong-670a0 表示主节点的主机名。Ray Worker 可以使用这个地址加入 Ray Head。

3. MASTER_PORT

- **作用：**指定主节点用于通信的端口号（所有节点需一致）。
- **示例：**MASTER_PORT=23456 表示使用 23456 端口进行进程间通信。

4. RANK

- **作用**：表示当前进程的全局唯一标识（从 0 到 WORLD_SIZE-1）。主节点的 RANK 必须为 0。
- **示例**：如果 RANK=0，表示当前进程是主进程。

这些变量是 PyTorch 分布式训练（如 torch.distributed.launch 或 torchrun）的核心配置，用于：

1. **初始化进程组**：通过 torch.distributed.init_process_group 实现多进程协作。
2. **协调通信**：确保所有进程能正确连接到主节点（MASTER_ADDR:MASTER_PORT）。
3. **数据并行**：结合 DistributedDataParallel (DDP) 实现多 GPU/多节点训练。

例如：

```
import torch.distributed as dist

dist.init_process_group(
    backend="nccl", # 或 "gloo"
    init_method=f"tcp://{os.environ['MASTER_ADDR']}:{os.environ['MASTER_PORT']}",
    world_size=int(os.environ['WORLD_SIZE']),
    rank=int(os.environ['RANK'])
)
```

以普通用户运行

自定义作业默认以 root 用户运行，这种情况下，由于 Jupyter 交互式作业默认以普通用户运行，可能会导致权限问题。

为了帮助您以普通用户运行自定义作业，我们在容器内注入了 /crater-start.sh 脚本，您可以通过以下方式使用：

方法1：直接执行命令

在批处理命令前加上脚本调用：

```
/crater-start.sh python your_script.py
```

方法2：多步骤执行

执行脚本后，指定以普通用户权限运行命令，若直接执行命令，则仍以root权限执行：

```
/crater-start.sh
su - ${NB_USER} -c 'your_command_1'
su - ${NB_USER} -c 'your_command_2'
...
```

RDMA

如果需要使用 RDMA，请先申请 GPU，之后在作业配置中启用 RDMA 选项。

启用后，CPU 和内存限制将被忽略。请注意，RDMA 资源配置必须在所有角色中保持一致。

相关文档有待补充。

 数据挂载

^

挂载源 1 *

×

文件

数据

DeepSeek-R1-Distill-Qwen-32B

⌵

挂载点 1 *

/models/DeepSeek-R1-Distill-Qwen-32B

可修改容器内的挂载路径

⊕ 添加 数据挂载

 环境变量

∨

 其他选项

^

接收状态通知 ?

☐

目标节点控制 ?

☐